

**SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE  
FAKULTA ELEKTROTECHNIKY A INFORMATIKY**

Evidenčné číslo: FEI-5384-72737

**DETEKCIA ŠPORTOVÝCH AKTIVÍT Z VIDEO  
SEKVENCIE  
DIPLOMOVÁ PRÁCA**

**2018**

**Bc. Marek Hrebík**

**SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE**  
**FAKULTA ELEKTROTECHNIKY A INFORMATIKY**

Evidenčné číslo: FEI-5384-72737

**DETEKCIA ŠPORTOVÝCH AKTIVÍT Z VIDEO**  
**SEKVENCIE**  
**DIPLOMOVÁ PRÁCA**

Študijný program:	Aplikovaná informatika
Číslo študijného odboru:	2511
Názov študijného odboru:	9.2.9 Aplikovaná informatika
Školiace pracovisko:	Ústav informatiky a matematiky
Vedúci záverečnej práce:	Ing. Dominik Sopiak
Konzultant:	Ing. Jozef Gerát

**Bratislava 2018**

**Bc. Marek Hrebík**

# SÚHRN

SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE  
FAKULTA ELEKTROTECHNIKY A INFORMATIKY

Študijný program:	Aplikovaná informatika
Autor:	Bc. Marek Hrebík
Diplomová práca:	Detekcia športových aktivít z video sekven- cie
Vedúci záverečnej práce:	Ing. Dominik Sopiak
Konzultant:	Ing. Jozef Gerát
Miesto a rok predloženia práce:	Bratislava 2018

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Aenean et est a dui semper facilisis. Pellentesque placerat elit a nunc. Nullam tortor odio, rutrum quis, egestas ut, posuere sed, felis. Vestibulum placerat feugiat nisl. Suspendisse lacinia, odio non feugiat vestibulum, sem erat blandit metus, ac nonummy magna odio pharetra felis. Vivamus vehicula velit non metus faucibus auctor. Nam sed augue. Donec orci. Cras eget diam et dolor dapibus sollicitudin. In lacinia, tellus vitae laoreet ultrices, lectus ligula dictum dui, eget condimentum velit dui vitae ante. Nulla nonummy augue nec pede. Pellentesque ut nulla. Donec at libero. Pellentesque at nisl ac nisi fermentum viverra. Praesent odio. Phasellus tincidunt diam ut ipsum. Donec eget est. A skúška mäččėňov a dlžnov.

Kľúčové slová: detekcia, rozpoznávanie, Motion History Image, Histogram of Oriented Gradients, Support Vector Machine

# ABSTRACT

SLOVAK UNIVERSITY OF TECHNOLOGY IN BRATISLAVA

FACULTY OF ELECTRICAL ENGINEERING AND INFORMATION TECHNOLOGY

Study Programme:	Applied Informatics
Author:	Bc. Marek Hrebík
Master's thesis:	Detection of sport activities from video sequence
Supervisor:	Ing. Dominik Sopiak
Consultant:	Ing. Jozef Gerát
Place and year of submission:	Bratislava 2018

On the other hand, we denounce with righteous indignation and dislike men who are so beguiled and demoralized by the charms of pleasure of the moment, so blinded by desire, that they cannot foresee the pain and trouble that are bound to ensue; and equal blame belongs to those who fail in their duty through weakness of will, which is the same as saying through shrinking from toil and pain. These cases are perfectly simple and easy to distinguish. In a free hour, when our power of choice is untrammelled and when nothing prevents our being able to do what we like best, every pleasure is to be welcomed and every pain avoided. But in certain circumstances and owing to the claims of duty or the obligations of business it will frequently occur that pleasures have to be repudiated and annoyances accepted. The wise man therefore always holds in these matters to this principle of selection: he rejects pleasures to secure other greater pleasures, or else he endures pains to avoid worse pains.

Keywords: detection, recognition, Motion History Image, Histogram of Oriented Gradients, Support Vector Machine

# Pod'akovanie

I would like to express a gratitude to my thesis supervisor.

# Obsah

<b>Úvod</b>	<b>1</b>
<b>1 Použité technológie a prostredie</b>	<b>2</b>
1.1 OpenCV . . . . .	2
1.2 FFmpeg . . . . .	2
1.3 Python . . . . .	2
1.4 Scikit a Numpy . . . . .	2
1.4.1 Scikit . . . . .	2
1.4.2 NumPy . . . . .	3
<b>2 Princíp spracovania obrazu a databázy</b>	<b>4</b>
2.1 Spôsob spracovania sekvencie . . . . .	4
2.1.1 Získanie časovo-priestorových vzťahov . . . . .	4
2.1.2 Extrakcia príznakov . . . . .	4
2.1.3 Návrh klasifikátora . . . . .	5
2.2 Databázy videí . . . . .	5
2.2.1 Vlastnosti videa . . . . .	5
2.2.2 Databázy ľudského pohybu . . . . .	6
2.3 Možnosti spracovania obrazu . . . . .	7
2.3.1 Motion History Image . . . . .	7
2.3.2 Histogram of Oriented Gradients . . . . .	8
2.3.3 Support Vector Machine . . . . .	11
<b>3 Návrh riešenia</b>	<b>14</b>
3.1 KTH Databáza . . . . .	14
3.2 Predspracovanie videa . . . . .	15
3.3 Výber príznakov . . . . .	17
3.4 Klasifikácia . . . . .	19
3.5 Opravy a priebežné testovania . . . . .	19
3.5.1 Prvotné testy . . . . .	19
3.5.2 Opravy a vylepšenie príznakov . . . . .	20
<b>4 Testovanie a porovnanie riešení</b>	<b>21</b>
<b>Záver</b>	<b>22</b>

<b>Zoznam použitej literatúry</b>	<b>23</b>
<b>Prílohy</b>	<b>I</b>
<b>A Štruktúra elektronického nosiča</b>	<b>II</b>
<b>B Algoritmy</b>	<b>III</b>
<b>C Výpis subline</b>	<b>V</b>

# Zoznam obrázkov a tabuliek

Obrázok 1	Funkcia zmeny pixelov v MHI . . . . .	8
Obrázok 2	Motion History image tleskania . . . . .	8
Obrázok 3	R-HOG a C-HOG . . . . .	10
Obrázok 4	Metódy normalizácie . . . . .	11
Obrázok 5	Príklad lineárne separovateľného problému . . . . .	12
Obrázok 6	Rozšírenie dimenzie v SVM . . . . .	13
Obrázok 7	Jednotlivé pohyby v datasete KTH [13] . . . . .	15
Obrázok 8	Predspracované videá boxu. . . . .	17
Obrázok 9	Test dvoch tried . . . . .	20
Obrázok 10	Test dvoch tried . . . . .	20



# Zoznam skratiek

**CDMA**    Code Division Multiple Access

**GSM**     Global System for Mobile communication

# Zoznam algoritmov

1	Ukážka príkazov pre algorithmic . . . . .	21
---	---	----

# Zoznam výpisov

1	Algoritmus MHI . . . . .	15
2	Algoritmus HOG . . . . .	17
3	Trénovanie klasifikátora . . . . .	19
B.1	Test TSNE . . . . .	III
C.1	Ukážka sublime-project . . . . .	V

# Úvod

Tu bude krásny úvod s diakritikou atď.

A možno aj viac riadkový úvod.

# 1 Použité technológie a prostredie

## 1.1 OpenCV

Open Source Computer Vision Library (OpenCV) bola pôvodne vydávaná firmou Intel, neskôr výskumným centrom Willow Garage, ktoré vyvíja open source softvér pre aplikácie na poli robotiky. Podporuje frameworky TensorFlow, Torch/PyTorch, Caffe. Knižnica je vydávaná pod BSD licenciou, čo umožňuje jej komerčné používanie. Táto knižnica obsahuje množstvo nástrojov a algoritmov na rozpoznávanie gest, identifikáciu objektov, segmentáciu a rozpoznávanie, spájanie obrazov, sledovanie pohybu, taktiež je vhodná pre implementáciu rozšírenej reality a strojového učenia. OpenCV je podporované v jazykoch C++, Python, Java, C a Matlab. Vývoj je umožnený na operačných systémoch Windows, Android, Linux a Mac. [1]

## 1.2 FFmpeg

Táto knižnica je voľný softvorový projekt určený na manipulovanie (kódovanie, dekódovanie, multiplexovanie, prehrávanie a streamovanie) s multimediálnymi súbormi. Má voľnú licenciu GNU (General Public License). Výhodou práce s knižnicou FFmpeg je jej rýchlosť a kvalita výstupných dát. Knižnicu využíva aj OpenCV pre spracovanie a distribúovanie obrazovej sekvencie. Obsahuje nástroje na zmenu kvality videa, strihanie, čo napomáha pri kontextovej analýze obrazu.[2]

## 1.3 Python

Programovací jazyk Python je interpretovaný vysokoúrovňový jazyk, vytvorený v roku 1991. Jeho využitie je široké, od vývoja webových aplikácií, backendu, frontendu cez vedecké a numerické výpočty, tvorbu grafických rozhraní, vývoj softvéru a výučbu a tvorbu biznis aplikácií. V súčasnosti má širokú podporu u programátorov, čo sa odráža aj na prehľadnom zdokumentovaní. Je to open source softvér s množstvom štandardných knižníc, ktoré majú široké využitie v automatizácii, multimédiách, spracovaní obrazu, textu a ďalších sférach IT.[3]

## 1.4 Scikit a Numpy

### 1.4.1 Scikit

Scikit-learn je knižnica s otvoreným zdrojovým kódom pre strojové učenie pre programovací jazyk Python. Scikit je napísaný v jazyku Python s niektorými algoritmami písanými v Cythone pre zvýšenie výkonu tejto knižnice. Obsahuje rôzne klasifikačné, regresné a zhlukovacie algoritmy, taktiež na modelovanie dát (krížová validácia, výber príznakov,

clustering a iné. Je navrhnutá na spoluprácu s numerickou knižnicou NumPy a vedeckou knižnicou SciPy. [4]

### **1.4.2 NumPy**

NumPy je rozšírenie do Pythonu, ktoré nám umožňuje rýchle a efektívne vykonávanie operácií nad poľami homogénnych dát. NumPy pole je multidimenzionálne pole objektov ktoré majú všetky rovnaký typ. V pamäti sa nachádza ako objekt, ktorý smeruje na blok pamäte, ktorý drží informáciu o type údajov v pamäti, počet dimenzií pamäte, veľkosť každej dimenzie a taktiež aj vzdialenosti medzi jednotlivými prvkami pozdĺž každej z osí. Narozdiel od klasického zoznamu, ktorý je implementovaný ako zoznam smerníkov je prehľadávanie NumPy poľa rýchlejšie. klasický zoznam potrebuje na iteráciu poľa prístup cez dva smerníky, čo predlžuje čas prehľadávania.[5]

## 2 Princíp spracovania obrazu a databázy

V prvej časti tejto práce si predstavíme a zároveň porovnáme metódy, ktoré sme zvažovali pri riešení nášho problému. Takisto si zhrnieme aké databázy pohybov máme k dispozícii pre potreby tejto práce, typy databáz, dĺžky jednotlivých videí, vlastnosti a aké druhy aktivít sa v týchto videách nachádzajú. Taktiež je potrebné predstaviť metodológiu spracovania údajov pre zachytenie vhodných vlastností videa na rozpoznanie.

### 2.1 Spôsob spracovania sekvencie

Zo zadania vyplýva, že pre získanie príznakov z videa budeme potrebovať videosekvenciu rozdeliť na menšie časti, respektíve ju spracovať do formátu obrázku (.jpg, .png alebo iné). Jednotlivé snímky z videa sú potrebné na hlbšiu analýzu. Podľa zvoleného datasetu budeme môcť zvoliť či budeme používať celú videosekvenciu, alebo iba jej časť, v ktorej je zrejмый druh pohybu. V jednotlivých triedach videí bude potrebné hľadať spoločné a rozdielne znaky na to, aby sme následne vybrali vhodný postup na spracovanie z získanie vhodných príznakov. Knížnica OpenCV neobsahuje metódy ktoré zabezpečia čítanie a prenos obrazu, avšak jej metódy využívajú funkcionality ďalšej knihnice FFmpeg, ktorá distribuuje prostredníctvom rozhrania jednotlivé obrazové snímky.

#### 2.1.1 Získanie časovo-priestorových vzťahov

Bude potrebné získať tieto vzťahy na porovnávanie s ďalšími videami, teda určenie vhodného spôsobu na získanie týchto vzťahov. Jedným zo spôsobov je napríklad algoritmus MHI (Motion History Image), ktorý nám môže zabezpečiť tieto príznaky z videa uložiť a ďalej spracovávať. Podľa tohto algoritmu by sme vedeli určiť odkiaľ kam sa aktér z videa pohyboval, akým spôsobom a rýchlosťou, čo môžeme považovať za prvé vhodné príznaky pre určenie typu pohybu.[6] Tento algoritmus si bližšie popíšeme ďalej v tejto práci.

#### 2.1.2 Extrakcia príznakov

Extrakcia príznakov je dôležitou časťou pre natrénovanie klasifikátora. Preto je potrebné vybrať príznaky, ktoré nám s čo najvyššou presnosťou zdefinujú konkrétny pohyb, ktorý sa bude vykonávať vo videu. Mali by to byť príznaky, ktoré sú jednoznačné a jedinečné pre každý z druhov pohybu. Preto musíme uvažovať vhodnú metódu extrahovania príznakov, aby sme zaistili diverzitu medzi triedami jednotlivých typov pohybu. Tieto príznaky budeme extrahovať z predspracovaného zdroja a ukladať na disk pre natrénovanie klasifikátora, prípadne viacnásobné tréningovanie a testovanie bude vhodné jednotlivé výsledky ukladať pre neskoršie porovnanie.

### 2.1.3 Návrh klasifikátora

Po úspešnom získaní príznakov z každej videosekvencie bude potrebné natrénovať klasifikátor tak, aby nám každá skupina spracovaných videozáznamov spadala do jednej triedy. Takto natrénovaný klasifikátor budeme potrebovať uložiť pre potreby testovania a porovnávania výsledkov a diverzity jednotlivých skupín. Zároveň budeme potrebovať zvoliť vhodný pomer dát na testovanie a tréning na základe Datábáz, ktoré budeme mať k dispozícii. Z tohto dôvodu budeme potrebovať čo najviac videí, aby bol návrh klasifikačnej metódy čo najpresnejší.

## 2.2 Databázy videí

Na internete je veľké množstvo video databáz s rôznymi pohybmi objektov, ľudí a zvierat. Výber databázy realizujeme na základe vlastností jednotlivých videí. Videá môžu byť snímané staticky z jedného miesta bez pohybu kamery, staticky s otáčaním kamery, taktiež dynamicky s rôznym pohybom a otáčaním kamery. Výber databázy bude najdôležitejšou súčasťou tejto práce, keďže od nej sa bude odvíjať celý ďalší postup.

### 2.2.1 Vlastnosti videa

Dôležitými vlastnosťami videí z databáz sú:

- veľkosť
- rozlíšenie
- dĺžka
- počet videí
- spôsob snímania
- formát videa
- počet objektov

**Veľkosť** videa ovplyvňuje vo vysokej miere časový úsek určený na spracovanie videa. Z tohto dôvodu je vhodné hľadať databázy videí, ktorých videá majú menšiu veľkosť, čo priamo súvisí s ich rozlíšením, počtom snímkov za sekundu a dĺžkou. Nesmieme ale zabudnúť na to, že video musí byť zreteľné a pohyb detekovateľný.

**Rozlíšenie** videa je dôležitým faktorom pre spracovanie z hľadiska kvality príznakov a snímkov. Zároveň jeho odporúčaná veľkosť sa líši od konkrétneho spôsobu extrakcie



príznakov. Dôležité je, aby obraz konkrétnej aktivity na videu bol jasný a voľným okom rozpoznateľný.

**Dĺžka** sekvencie sa líši od rozmanitosti jednotlivých pohybov osoby. Niektoré databázy obsahujú videosekvencie s opakovaním pohybov, teda dĺžka videí v týchto databázach je väčšia ako v tam, kde je daná aktivita alebo pohyb zachovaný bez opakovania.

**Počet videí** môže ovplyvniť výsledok a efektivitu rozpoznávania aktivít. Niektoré databázy obsahujú malé množstvo videí pre jeden konkrétny pohyb (okolo 10 až 20), iné zdroje videosekvencií ich majú aj viac ako 50 pre jeden typ pohybu.

**Spôsob snímania** v rozpoznávaní pohybu je dôležitou vlastnosťou, keďže nie všetky spôsoby riešenia je možné aplikovať na videá s pohybujúcou sa kamerou a opačne.

**Formát videa** súvisí s jeho veľkosťou, avšak formát je možné meniť a konvertovať na nami potrebný rozmer.

**Počet objektov**, ktoré sa na videu pohybujú a vyhodnocujú vplýva na výkon a rýchlosť rozpoznávania. Tu taktiež nie je možné aplikovať niektoré metódy rozpoznávania.

### 2.2.2 Databázy ľudského pohybu

Pre potrebu rozpoznávania pohybu osoby existuje viacero databáz, ktoré sme v našej práci uvažovali a testovali:

- HMDB51
- KTH
- UCF-Sports
- Hollywood
- MSR Action I, II
- IXMAS
- WEIZMANN

**HMDB51** je databáza pohybov v ktorej sa nachádza 51 tried pohybu a gestikulácie ako napríklad česanie vlasov, žuvanie, lezenie, potápanie, chôdza atď. Celkovo obsahuje 6849 videí s rozlíšením 320 x 240 pixelov. Videá sú so statickou aj dynamickou kamerou. Zdrojom videí je YouTube ako aj iné verejne dostupné databázy videí. Videá sú špecifické vysokou diverzitou kvality ako aj pohybu.[7]

**KTH** pohybová databáza so šiestimi triedami - chôdza, pomalý beh, beh, boxovanie, kývanie rukou, tlieskanie. V každej z týchto tried sa nachádza 100 čiernobielych videí s

rozlíšením 160 x 120 pixelov so statickou kamerou. Videá sú natočené v interiéri ako aj exteriéri. [7]

**UCF-Sports** obsahuje 9 tried pohybu so 182 videami so statickou aj dynamickou kamerou. Rozlíšenie videí je 720 x 480 pixelov. Videá sú z rôznych športových podujatí vysielaných v televízii - skok do vody, vzpieranie, jazda na koni a iné.[7]

**Hollywood** databáza obsahuje 8 tried - vystúpenie z vozidla, bozkávanie, postavenie sa, sadnutie si a iné. Nachádza sa tam 430 videí s rozlíšením 300 - 400 x 200 - 300 pixelov s dynamickou kamerou a dynamickým pozadím.[7]

**MSR Action I, II** obsahujú 3 triedy pohybu so statickou kamerou a 16-timi videami s rozlíšením 320 x 240 pixelov. Namodelované videá sú určené na detekciu pohybu, nie jeho rozpoznávanie. Vo videách sa nachádza viac ako jeden pohyb. V pozadí sa objavujú aj iné osoby, prípadne objekty ako auto. [7]

**IxMAS** alebo *INRIA Xmas Motion Acquisition Sequences* obsahuje 13 tried s rozlíšením 390 x 291. Pohyb je zaznamenávaný z viacerých statických kamier. [7]

**WEIZMANN** obsahuje 10 tried pohybu, celkový počet videí je 90. Obsahujú triedy pohybu ako chôdza, beh, kývanie jednou alebo dvomi rukami, skok na mieste a iné. Videá sú natočené so statickou kamerou a pozadím v interiéri s rozlíšením 180 x 144. [7]

## 2.3 Možnosti spracovania obrazu

Na získanie príznakov a potrebu klasifikácie pohybu analyzujeme a zvažujeme konkrétne spôsoby spracovania obrazu z videa. Pre tento účel berieme v úvahu algoritmus Motion history image (MHI) na extrakciu prvotných príznakov a následné spracovanie pomocou Histogram of oriented gradients (HOG). Takto získané príznaky by sme následne vedeli natrénovať pomocou Support vector machine (SVM). Z natrénovanej SVM vieme otestovať úspešnosť klasifikátora, ktorý sme natrénovali a tým sa dostať ku výsledkom.

### 2.3.1 Motion History Image

MHI je metódou, ktorá je založená na časovej šablóne. Je to jednoduchá metóda avšak robustná, vhodná na reprezentovanie a analýzu pohybu.[6] Táto metóda bola prvýkrát popísaná v dokumente “An appearance-based representation of action” od Aarona Bobicka a Jamesa W. Davisa.[8] Rozpoznávanie akcie pomocou MHI patrí do skupiny prispôbovania šablóny. V MHI sa informácia pohybu v čase spája do jedného obrázku, kde intenzita pixelov je funkciou histórie pohybu na danej pozícii pixelu. MHI sa vypočítava pomocou aktualizáčnej funkcie.<sup>1</sup>

Táto aktualizáčná funkcia je volaná pre každý ďalší snímok, ktorý analyzujeme z videosekvencie. Výsledkom tohto výpočtu je skalárny snímok, v ktorom svetlejšie časti

$$H_{\tau}(x, y, t) = \begin{cases} \tau & \text{ak } \Psi(x, y, t) = 1 \\ \max(0, H_{\tau}(x, y, t-1) - \delta) & \text{inak} \end{cases}$$

$(x, y, t)$  – pozícia pixelu a čas

$\Psi(x, y, t)$  – prítomnosť (alebo pohyb) objektu v poslednom snímku


$\tau$  – dĺžka určujúca časový rozsah pohybu (jednotlivých snímkov)

$\delta$  – parameter stmavnutia pixelu

Obr. 1: Funkcia zmeny pixelov v MHI

obrázku označujú najnovšie menené pixely a tmavšie sú tie, ktoré boli menené dávnejšie z pohľadu pohybu na videu.

To nám umožňuje zaznamenať pohyb z videa do jediného obrázku, v ktorom je vystihnutý celý priebeh videa alebo jeho časti. Táto technika je vhodná na použitie pri videách so statickou kamerou a pozadím.[9]



Obr. 2: Motion History image tieskania

Na obrázku 2 je príklad spracovaného pohybu z videa do MHI, na ktorom môžeme vidieť pohyb tela pri akcii tieskania.

### 2.3.2 Histogram of Oriented Gradients

HOG je metóda extrakcie príznakov z obrazu. Extrahuje príznaky z každej časti vstupného obrazu. Snaží sa zachytiť tvar štruktúry v regiónoch pomocou prechodov farieb jednotlivých pixelov. Rozdeľuje obraz na menšie spojené časti (napríklad 8 x 8 pixelov)a

tie časti do ešte menších blokov z ktorých sa následne zostavuje histogram. Deskriptor je spojenie týchto histogramov. Každá z týchto častí má rovnaký počet orientácií gradientu. Pre zvýšenie presnosti môžu byť lokálne histogramy normalizované na základe kontrastu a výpočtom miery intenzít naprieč väčšími časťami obrazu, teda bloku. Táto normalizácia vedie k zvýšenej invariantnosti pri zmene osvetlenia alebo tienenia. HOG Deskriptor má výhody v tom, že pôsobí na lokálne bunky, je invariantný voči geometrickým a fotometrickým transformáciám. N. Dalal a B. Triggs zistili, že hrubé priestorové vzorkovanie, jemné vzorkovanie a silná lokálna fotometrická normalizácia umožňujú HOG deskriptoru vhodne detekovať ľudské bytosti v obrazoch.

**Výpočet gradientu** Základným krokom pri HOG algoritme je výpočet gradientových hodnôt. Najbežnejšou metódou je aplikácia 1-D centrovanej diskkrétnej masky v horizontálnom alebo aj vertikálnom smere. Táto metóda vyžaduje filtrovanie farieb alebo intenzitu obraz s filtračnými jadrami.

**Histogram orientovaných gradientov** Ďalším krokom je vytvorenie histogramu orientovaných gradientov. Každý pixel v bunke pridáva svoju ováňovanú orientáciu pre orientovaný histogramový kanál, ktorý je vytvorený na základe výpočtu gradientov. Bunky môžu byť obdĺžnikového alebo radiálneho tvaru a histogramové kanály sú rozložené rovnomerne od 0 do 180 alebo 0 - 360 stupňov, záleží od toho, či gradienty môžu nadobúdať aj zápornú hodnotu, alebo nie. Podľa výskumov N. Dalala a B. Triggsa bolo zistené, že najvhodnejší počet kanálov na detekovanie osoby je 9 pri rozsahu 0 - 360 stupňov.

**Bloky deskriptorov** Na zohľadnenie zmien v osvetlení a kontraste musí byť intenzita gradientu lokálne normalizovaná, čo vyžaduje spoločné zoskupovanie buniek do väčších priestorovo prepojených blokov. HOG Deskriptor je následne spojený vektor komponentov normalizovaných histogramov buniek zo všetkých oblastí blokov. Tieto bloky sa prekrývajú, z čoho vyplýva, že každý jedna bunka prispieva voac ako raz do vytvorenia konečného deskriptora. Existujú dva hlavné tvary blokov:

- **R-HOG** (Rectangular HOG)
- **C-HOG** (Circular HOG)

**R-HOG** - sú štvorcové mriežky reprezentované tromi parametrami:

- počet buniek v bloku
- počet pixelov v bunke


- počet kanálov na histogram bunky

V práci N. Dalala a B. Triggsa je uvedené, že optimálne parametre sú štyri pixelové bunky s veľkosťou 8 x 8 na jeden blok (16 x 16 pixelov na blok) s deviatimi histogramovými kanálmi. Bolo taktiež zistené, že menšie vylepšenie vo výkonnosti môže byť nadobudnuté použitím Gaussovho priestorového okna v každom bloku pred zaznamenaním váhovaných histogramov. Lepšiemu výsledku by napomohlo to, že okrajové pixely by boli ováňované nižšími hodnotami.

**C-HOG** - sú kruhové bloky, ktoré je možné použiť v dvoch variantoch. Jednou variantou je využitie jednej centrálnej bunky, pri druhej variante je táto bunka uhlovo rozdelená do rovnakých častí. Tieto bloky sú popísané štyrmi parametrami:

- počet uhlových buniek
- počet radiálnych buniek
- polomer stredovej bunky
- faktor expanzie pre polomer dodatočných radiálnych buniek

Podľa zistení N. Dalala a B. Triggsa najvhodnejšie zvoleným spôsobom je vytvorenie dvoch radiálnych buniek so štyrmi uhlovými bunkami, polomerom stredovej bunky 4 pixely a faktor expanzie s hodnotou 2.



Obr. 3: R-HOG a C-HOG

Na obrázku 3 môžeme vidieť ako vyzerá rozdelenie obrazu podľa R-HOG a C-HOG.

$$L2 - norm \quad \rightarrow \quad f = \frac{v}{\sqrt{\|v\|_2^2 + e^2}}$$

$$L2 - hys \quad \rightarrow \quad L2 - norm \text{ s hodnotou } v < 0.2$$

$$L1 - norm \quad \rightarrow \quad f = \frac{v}{(\|v\|_1 + e)}$$

$$L1 - sqrt \quad \rightarrow \quad f = \sqrt{\frac{v}{(\|v\|_1 + e)}}$$

$v$  – nenormalizovaný vektor obsahujúci histogramy daného bloku  
 $\|v\|_k$  – je  $k$  norma ( $k = 1, 2$ )  
 $e$  – malá konštanta

Obr. 4: Metódy normalizácie

**Normalizácia blokov** Sú štyri rôzne spôsoby normalizácie blokov, ktoré sú popísané na obrázku 4.

Schéma **L2-hys** môže byť vypočítaná z **L2-norm**, kde sa výsledok renormalizuje pre vektor  $v < 0.2$ . Všetky štyri normy majú výrazne lepšie výsledky ako nenormalizované dáta. Tieto údaje sú následne použiteľné ako vektor príznakov pre SVM. [10]

### 2.3.3 Support Vector Machine

SVM je metóda strojového učenia s učiteľom, je vhodná na používanie pri klasifikácii alebo regresnej analýze. Táto metóda na základe tréningových vzoriek, ktoré sú priradené do jednej z dvoch tried vytvorí model. Tento model je následne schopný priradovať nové vzorky do jednej z týchto tried, čo z neho robí nepravdepodobnostný binárne lineárny klasifikátor. SVM model reprezentuje vzorky ako body v priestore, tak, že mapuje jednotlivé vstupy do kategórií, ktoré sú v tomto priestore jasne oddelené. Klasifikátor priraduje nové vzorky podľa toho, ku ktorej z tried majú bližšie v rámci tohto priestoru.

Okrem lineárnej klasifikácie je SVM schopné efektívne riešiť aj nelineárne separovateľné problémy pomocou takzvaného kernel triku. Pokiaľ dáta nie sú pri tréningu označené, do ktorej kategórie patria, učenie s učiteľom nie je možné, avšak je možné učenie bez učiteľa tak, že algoritmus sa snaží nájsť prirodzené zoskupenie dát a tak ich rozdeliť do kategórií.

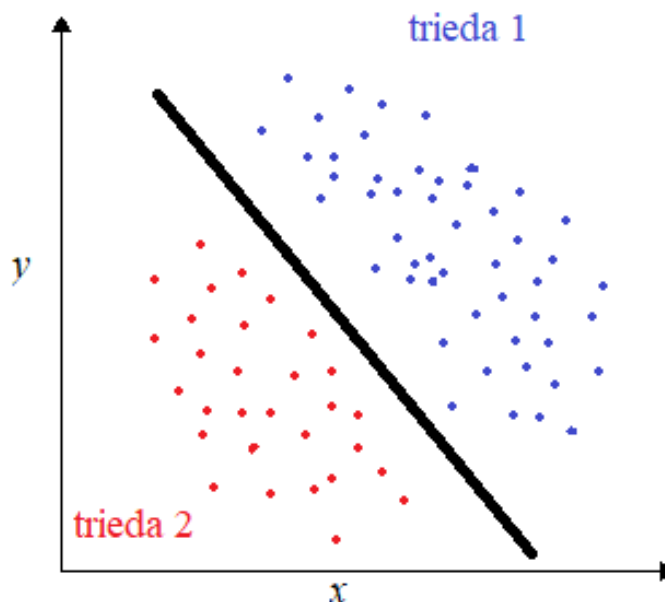
SVM algoritmus vytvorili Hava Siegelmann a Vladimir Vapnik. Tento algoritmus má široké využitie a je používaný v priemyselných aplikáciách, počítačovom videní, umelej

inteligencii. [11]

**Definícia algoritmu** SVM vytvára hyperrovinu <sup>1</sup>, alebo viacero hyperrovín, vo vysokorozmernom priestore, ktorý môže byť použitý na klasifikáciu, regresiu alebo iné úlohy. Dobrá separácia sa dosiahne vtedy, keď hyperrovina má veľkú vzdialenosť od najbližšieho tréningového bodu akejkoľvek triedy. Teda platí, čím je väčšia vzdialenosť hyperroviny od tréningových údajov, tým je nižšia chyba klasifikátora pri určovaní triedy testovacej vzorky.[12]

Keďže nie všetky problémy je možné lineárne separovať, bolo navrhnuté, aby sa priestor, ktorý SVM spracováva rozvrhol do viacrozmerného priestoru, čo uľahčí rozdelenie jednotlivých dát do tried. Pre zanechanie výpočtovej rýchlosti je mapovanie v SVM navrhnuté v pôvodnom priestore, kde sa následne zvolí vhodná kernelová funkcia  $k(x, y)$ . Hyperroviny vo viacrozmernom priestore sú definované ako súbory bodov, kde ich vektory majú konštantnú dĺžku. Následne body z priestoru príznakov sú mapované do hyperroviny.

**Lineárny klasifikátor** Najjednoduchšou možnosťou použitia SVM je prípad lineárneho klasifikátora pre dáta, ktoré je možné lineárne rozdeliť do dvoch tried pomocou hyperroviny. Príklad takéhoto problému je na obrázku 5.




Obr. 5: Príklad lineárne separovateľného problému

---

<sup>1</sup>Podpriestor, ktorý má o jednu dimenziu menej ako priestor, v ktorom sa nachádza.

**Nelineárny klasifikátor** Na obrázku č. 6 môžeme vidieť lineárne neseparovateľný problém dvoch množín, ktorý sa po pridaní tretej dimenzie stáva lineárne separovateľný. Takýmto spôsobom dokážeme s SVM zatriediť jednotlivé videá z množín do správnych tried. Transformácia do vyššierozmerného priestoru sa nazýva jadrový trik (*angl. kernel trick*). Pomocou tohto triku vieme lineárne separovať aj lineárne neseparovateľné problémy.[12]



Obr. 6: Rozšírenie dimenzie v SVM

Medzi najčastejšie používané jadrové funkcie patria:

- **Polynóm stupňa  $p$**
- $K(x, y) = (x \cdot y + 1)^p$
- **Radiálne bázové funkcie**
- $K(x, y) = e^{(-\|x-y\|^2/2\sigma^2)}$
- **Dvojvrstvová neurónová sieť**
- $K(x, y) = \tanh(\kappa x \cdot y - \delta)$



## 3 Návrh riešenia

Po oboznámení s teoretickými piliermi tejto práce prejdeme ku konkrétnemu riešeniu témy a implementácii, ktorú sa nám podarilo vytvoriť. Postupne prejdeme jednotlivé kroky vytvárania programu od analýzy datasetov, načítavania a ukladania videosekvencií do obrazkových formátov. Ďalej si ukážeme metódy a spôsoby, ktorými sme následne vzniknuté dáta spracovali pre potrebu výberu príznakov a zatriedenia do jednotlivých tried. Fungovanie programu priblížime aj časťami kódu s popisom, na čo slúži a ako pracuje. Súčasťou tejto kapitoly bude aj krátky popis zmien, ktoré sme počas návrhu tejto implementácie vykonali a samozrejme aj ich dopad na finálne riešenie.

### 3.1 KTH Databáza

Pre naše riešenie sme vybrali z viacerých datasetov, ktoré boli popísané v kapitole 2.2.2. Nakoniec sme sa rozhodli pre databázu KTH, v ktorej máme 6 tried pohybu a nachádza sa pri každom z nich 100 videí. Naše rozhodnutie sme učinili takto z viacerých dôvodov. Potrebovali sme dataset, v ktorom sa nachádza veľké množstvo videí, zároveň vo videách sme potrebovali statickú kameru so statickým pozadím, aby sme predišli zvýšenému šumu. V tejto databáze sú pohyby:

- Boxovanie
- Mávanie rukami
- Tlieskanie rukami
- Beh
- Pomalý beh
- Chôdza

Pri analýze snímok sme zistili, že dĺžka videí je od **8 do 59 sekúnd**. Čo pre dané typy pohybov je postačujúci čas na to, aby sme z nich dokázali extrahovať dôležité informácie, ktoré sa tohto pohybu týkajú. Počet snímok za sekundu v každom z videí je 25, z tohto dôvodu sme usúdili, že aj v prípade krátkeho videa s dĺžkou 8 sekúnd budeme mať k dispozícii minimálne **200** snímok. Ďalším dôležitým faktom je, že sa budeme musieť popasovať s podobnosťou pohybov behu, pomalého behu a chôdze, keďže sú veľmi podobné, a ich rozdiel je iba v rýchlosti vykonávania. Je nutné dodať, že v každom z videí sa jednotlivé typy pohybov opakovali viacnásobne, z čoho sme už vopred usudzovali, že

na spracovanie nám bude stačiť iba časť videa, čo nám ušetrí čas spracovania dát počas behu programu.



Obr. 7: Jednotlivé pohyby v datase KTH [13]

Na obrázku 7 vidíme všetky kategórie pohybov, jednotlivé pohyby vykonáva viacero osôb rôznymi spôsobmi, teda je medzi týmito pohybmi aj diverzita, ktorá je určite vhodná na tréning pohybu.

### 3.2 Predspracovanie videa

Na predspracovanie videa a vytiahnutie prvotných príznakov sme sa rozhodli z našich videí vytvoriť obrázky, na ktorých sa bude nachádzať história pohybu. Algoritmus MHI, ktorý sme pri tom použili sme popísali v časti 2.3.1. Tento algoritmus sme zvolili na základe toho, že máme databázu videí bez pohyblivého pozadia, teda predídeme šumom na pozadí a budeme sa môcť venovať iba pixelom, ktoré menia svoju pozíciu v rámci videa. Presne to je postačujúca podmienka na to, aby sme bez väčších problémov mohli implementovať funkcionality algoritmu MHI na nami zvolený dátový rozsah. Vytvoriť MHI sme sa rozhodli zo všetkých videí, aby sme následne videli, akým spôsobom prebehlo spracovanie, či je možné z MHI vyčítať pohyb a jeho základné znaky.

```

def getImage(cam, video_src, vidDir):
    while True:
        ret, frame = cam.read()
        h, w = frame.shape[:2]
        prev_frame = frame.copy()
        motion_history = np.zeros((h, w), np.float32)
        timestamp = 0
        while True:
            frame_num = frame_num + 1
            ret, frame = cam.read()
            if not ret:
                break
            frame_diff = cv2.absdiff(frame, prev_frame)
            gray_diff = cv2.cvtColor(frame_diff, cv2.COLOR_BGR2GRAY)
            ret, fgmask = cv2.threshold(gray_diff, DEFAULT_THRESHOLD, 1, cv2.THRESH_BINARY)
            timestamp += 1
            # update motion history
            cv2.motempl.updateMotionHistory(fgmask, motion_history, timestamp, MHI_DURATION)
            # normalize motion history
            mh = np.uint8(np.clip((motion_history-(timestamp-MHI_DURATION)) / MHI_DURATION, 0, 1)*255)
            cv2.imshow('motempl', mh)
            print frame_num
            if frame_num == 160:
                frame_num = 0
                imagename = video_src[0:-4] + '.jpg'
                cv2.imwrite(MHI_dir + '\\\\' + vidDir + '\\\\' + imagename, mh)
                return

```

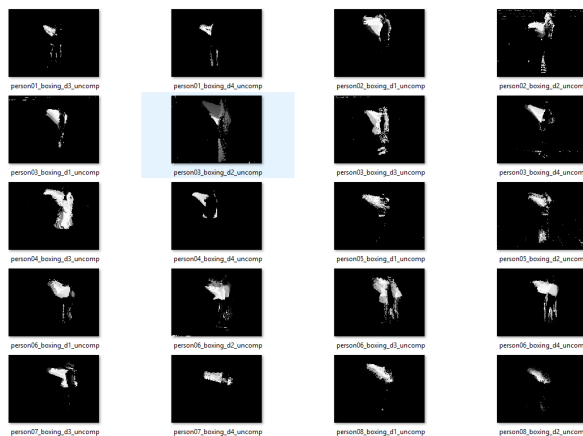
Listing 1: Algoritmus MHI

V tejto ukážke 1 kódu je celý proces čítania videa a jeho jednotlivých snímok za sebou so spracovaním na MHI. Funkcia *getImage* obsahuje tri vstupné parametre:

- **cam**
- **video\_src**
- **vidDir**

**cam**, čo je objekt typu *VideoCapture*, ktorý sa ďalej spracováva po jednotlivých snímkoch. Parameter **video\_src** je názov videosúboru, ktorý sme použili na uloženie obrázku z videa. **vidDir** je názov priečinku, v ktorom sa obrázok MHI bude ukladať. Na čítanie snímok sme použili knižnicu OpenCV, ako aj na spracovanie jednotlivých snímok do MHI. Dôležitými parametrami, ktoré sme nastavovali boli *frame\_num*, ktorý nám označoval počet prehratých snímok, pri ktorom sme uložili vyhotovené MHI, ďalej to bol *DEFAULT\_THRESHOLD*, ktorý nám filtroval nepotrebné pixely s veľmi nízkou hodnotou, pri tréovaní a testovaní sme zistili, že hodnota **50** bude dobrá. Akonáhle bol tento parameter vyšší alebo nižší, obrázky už neboli až tak dobre vyhodnocované.

Ďalším dôležitým parametrom je *MHI\_DURATION*. Tento parameter nám vymedzuje dĺžku histórie pohybu v jednotke *timestamp*, akú má snímať. čím je hodnota vyššia, tým dlhšia história pohybu je na finálnom MHI zaznamenaná. Pre naše potreby sme zvolili tento parameter na hodnotu **80**.



Obr. 8: Predspracované videá boxu.

Na obrázku 8 môžeme vidieť príklad už predspracovaných MHI prostredníctvom nášho algoritmu. Takto sme si vytvorili všetkých 600 obrázkov z pohybov na ďalší výber príznakov.

### 3.3 Výber príznakov

Keďže už máme predspracovaný obraz vo forme MHI, môžeme pokračovať v extrahovaní príznakov z týchto obrazov. Na tento účel sme zvolili deskriptor HOG popísaný v časti 2.3.2. Týmto spôsobom vytvoríme vektor príznakov, ktorý budeme môcť následne dať trénovať do klasifikátora pre každý jeden pohyb z trénovacej množiny. Príznačky z každého MHI obrázku by mali byť v tvare vektora konštantnej dĺžky.

```
image = cv2.imread('image.jpg', 0)

def hogCreate(image):
    winSize = (64,64)
    blockSize = (16,16)
    blockStride = (8,8)
    cellSize = (8,8)
    nbins = 9
    winSigma = 4.
    gammaCorrection = 0
    nlevels = 64
    hog = cv2.HOGDescriptor(winSize, blockSize, blockStride, cellSize, nbins, winSigma,
                             gammaCorrection,nlevels)
    winStride = (8,8)
    padding = (8,8)
```

```
locations = ((10,20),)
hist = hog.compute(image,winStride,padding,locations)
arrVectorFinal.append(np.concatenate(hist))
```

Listing 2: Algoritmus HOG

V tomto algoritme 2 vstupuje do funkcie *hogCreate* parameter *image* je vlastne obrázkom, ktorý je výstupom funkcie *imread* z knižnice OpenCV. Pre dobré vybratie príznakov je potrebné nastaviť a vytvoriť *HOGDescriptor*, ktorý obsahuje viacero parametrov:

- `winSize`
- `blockSize`
- `blockStride`
- `cellSize`
- `nbins`
- `gammaCorrection`
- `nlevels`

**winSize** parameter určuje veľkosť okna na detekciu, musí byť zarovnaný podľa *blockStride* a *blockSize*.

**blockSize** je veľkosť bloku v pixeloch. Má byť zarovnaný na veľkosť bunky *cellSize*.

**blockStride** musí byť násobkom veľkosti bunky, znamená veľkosť kroku, ktorým sa blok bude posúvať.

**cellSize** je veľkosť bunky.

**nbins** je počet rozdelení uhlov do ktorých jednotlivé gradienty zapadajú.

**gammaCorrection** hodnota určuje, či sa má použiť predspracovanie gamma úpravy alebo nie.

**nlevels** určuje maximálny počet detekčných okien, predvolená hodnota je 64.

Po takomto nastavení deskriptora HOG môžeme následne spracovať vstupný obraz a vytvoriť tak histogram hodnôt, ktoré už sú reprezentovateľné príznaky, ktoré vložíme do vektora príznakov *arrVectorFinal*. Konečným výstupom je teda pole vektorov, ktoré obsahuje príznaky extrahované zo všetkých testovacích videí. Tento vektor vieme následne použiť pre tréning klasifikátora.

## 3.4 Klasifikácia

Pre natrénovanie klasifikátora sme sa rozhodli použiť SVM, ktorý sme popísali v časti 2.3.3. Na implementovanie SVM sme použili triedu *svm* z knižnice *sklearn*. K dátam, ktoré máme uložené v *arrVectorFinal* potrebujeme ešte označenie, ktorý vektor do akej kategórie patrí. Preto sme vytvorili ďalší vektor, v ktorom je pre každé video označenie kategórie, kam vektor patrí. Teraz už môžeme natrénovať SVM.

```
clf = svm.SVC(decision_function_shape='ovr')
clf.fit(arrVectorFinal, classVector)
joblib.dump(clf, 'Model.pkl')
```

Listing 3: Trénovanie klasifikátora

Algoritmus 3 využíva volanie funkcií *svm.SVC*, ktoré nám vytvorí klasifikátor (angl. Support Vector Classifier), rozhodovaciu funkciu sme zvolili *ovr* (angl. one versus rest), keďže máme viac ako dve triedy pohybov. Následne prostredníctvom funkcie *fit* sme natrénovali klasifikátor *clf*, kde boli vložené vektory príznakov *arrVectorFinal* a vektor tried *classVector*. Takto natrénovaný model bolo potrebné uložiť pre ďalšie použitie a testovanie.

## 3.5 Opravy a priebežné testovania

Po naprogramovaní všetkých základných častí nášho projektu sme potrebovali otestovať naše riešenie, či náš klasifikátor funguje dobre a či môžeme prejsť ku finalizácii výsledkov.


Aby sme vedeli výsledok tréningu našej SVM, potrebovali sme výsledky vizualizovať, ako prebehlo rozdelenie do tried. Na to sme využili testovací nástroj *TSNE*, ktorého algoritmus nájdete v prílohe B.

### 3.5.1 Prvotné testy


Ako prvý krok sme zvolili testovanie a tréning dvoch množín a teda beh a boxovanie. SVM sme natrénovali na tridsiatich videách z triedy behu a tridsiatich videách z triedy boxovania.

Výsledok tréningu bol pre nás dobrý, keďže už vizuálne bolo vidno rozdelenie týchto pohybov do dvoch tried. Výsledok môžete vidieť na obrázku 9.

Do ďalšieho tréningu sme zapojili 5 tried pohybov, teda dataset KTH bez triedy pomalého behu. Takto natrénované SVM sme znovu podrobili testu *TSNE*, kde výstup vyzeral ako na obrázku 10, výsledky síce dávali zmysel, avšak rozdelenie jednotlivých tried nebolo až tak prehľadné ako sme si predstavovali, preto sme sa rozhodli analyzovať náš postup a pristúpiť k optimalizácii riešenia a zbieraniu ďalších príznakov.



Obr. 9: Test dvoch tried pohybu



Obr. 10: Prvý test piatich tried pohybu

### 3.5.2 Opravy a vylepšenie príznakov

## 4 Testovanie a porovnanie riešení

---

**Algorithm 1** Ukážka príkazov pre algorithmic

---

```
<text>
if <condition> then
    <text>
else
    <text>
end if
if <condition> then
    <text>
else if <condition> then
    <text>
end if
for <condition> do
    <text>
end for
for <condition> to <condition> do
    <text>
end for
for all <condition> do
    <text>
end for
while <condition> do
    <text>
end while
repeat
    <text>
until <condition>
loop
    <text>
end loop
Require: <text>
Ensure: <text>
return <text>
print <text> {<text>} and , or , xor , not , to , true, false
```

---



# Záver

Conclusion is going to be where?

Here.

# Zoznam použitej literatúry

1. *About - OpenCV library* [<https://opencv.org/about.html>]. (Accessed on 04/23/2018).
2. *Developer Documentation* [<http://ffmpeg.org/developer.html>]. (Accessed on 04/28/2018).
3. *Applications for Python | Python.org* [<https://www.python.org/about/apps/>]. (Accessed on 04/23/2018).
4. PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*. 2011, roč. 12, s. 2825–2830.
5. *Frequently Asked Questions — SciPy.org* [<https://www.scipy.org/scipylib/faq.html#what-is-numpy>]. (Accessed on 04/28/2018).
6. AHAD, Md. Atiqur Rahman, TAN, Joo Kooi, KIM, Hyoungseop a ISHIKAWA, Seiji. Motion history image: its variants and applications. *Machine Vision and Applications*. 2010, roč. 23, s. 255–281.
7. [https://www.cs.utexas.edu/~chaoyeh/web\\_action\\_data/dataset\\_list.html](https://www.cs.utexas.edu/~chaoyeh/web_action_data/dataset_list.html) [[https://www.cs.utexas.edu/~chaoyeh/web\\_action\\_data/dataset\\_list.html](https://www.cs.utexas.edu/~chaoyeh/web_action_data/dataset_list.html)]. (Accessed on 04/22/2018).
8. A. BOBICK, J. Davis. *An appearance-based representation of action - IEEE Conference Publication* [<https://ieeexplore.ieee.org/document/546039?denied>]. 1996. (Accessed on 04/23/2018).
9. AHAD, Md. Atiqur Rahman, TAN, Joo Kooi, KIM, Hyoungseop a ISHIKAWA, Seiji. Motion history image: its variants and applications. *Machine Vision and Applications*. 2010, roč. 23, s. 255–281.
10. DALAL, Navneet a TRIGGS, Bill. *Histograms of Oriented Gradients for Human Detection* [<http://lear.inrialpes.fr/people/triggs/pubs/Dalal-cvpr05.pdf>]. 2008. (Accessed on 04/28/2018).
11. SCHOLKOPF, Bernhard a SMOLA, Alexander J. *Learning with Kernels: Support Vector Machines, Regularization, Optimization, and Beyond*. Cambridge, MA, USA: MIT Press, 2001. ISBN 0262194759.
12. HASTIE, Trevor, TIBSHIRANI, Robert a FRIEDMAN, Jerome. <https://web.stanford.edu/~hastie/Papers/ESLII.pdf> [<https://web.stanford.edu/~hastie/Papers/ESLII.pdf>]. (Accessed on 04/28/2018).

13. YOUSEFI, B a CHU KIONG, Loo. Comparative Study on Interaction of Form and Motion Processing Streams by Applying Two Different Classifiers in Mechanism for Recognition of Biological Movement. 2014, roč. 2014, s. 723213.

# Prílohy

A	Štruktúra elektronického nosiča . . . . .	II
B	Algoritmy . . . . .	III
C	Výpis subline . . . . .	V

# A Štruktúra elektronického nosiča

*/CHANGELOG.md*

- file describing changes made to FEIstyle

*/example.tex*

- main example *.tex* file for diploma thesis

*/example\_paper.tex*

- example *.tex* file for seminar paper

*/Makefile*

- simply Makefile – build system

*/fei.sublime-project*

- is project file with build in Build System for Sublime Text 3

**/img**

- folder with images

**/includes**

- files with content

*/bibliography.bib*

- bibliography file

*/attachmentA.tex*

- this very file

# B Algoritmy

```
import numpy as np
from sklearn.decomposition import PCA, IncrementalPCA
import matplotlib.pyplot as plt
import matplotlib.patches as mpatches
from sklearn import manifold

trainData = np.load('arrVectorFinal.npy')
bag_of_labels = np.load('classVector.npy')

print(trainData.shape)

n_components = 200
ipca = IncrementalPCA(n_components=n_components, batch_size=200)
X_ipca = ipca.fit_transform(trainData)

#print 'Explained variation per principal component: {}'.format(ipca.explained_variance_ratio_)
print("Sum {}".format(np.sum(ipca.explained_variance_ratio_)))

colors = ['navy', 'turquoise', 'darkorange', 'red', 'wheat', 'yellow']
        #navy-vojnove_lodstvo, turquoise-tyrkysova(modro-zelena)

bag_of_labels = np.squeeze(bag_of_labels)

if False:
    area = np.full(X_ipca.shape, 25)
    plt.scatter(X_ipca[bag_of_labels == 1,0], X_ipca[bag_of_labels == 1,1], s=area, c=colors[0])
    plt.scatter(X_ipca[bag_of_labels == 2,0], X_ipca[bag_of_labels == 2,1], s=area, c=colors[1])
    plt.scatter(X_ipca[bag_of_labels == 3,0], X_ipca[bag_of_labels == 3,1], s=area, c=colors[2])
    plt.scatter(X_ipca[bag_of_labels == 4,0], X_ipca[bag_of_labels == 4,1], s=area, c=colors[3])
    plt.scatter(X_ipca[bag_of_labels == 5,0], X_ipca[bag_of_labels == 5,1], s=area, c=colors[4])
    plt.scatter(X_ipca[bag_of_labels == 6,0], X_ipca[bag_of_labels == 6,1], s=area, c=colors[5])

    plt.show()
    plt.gcf().clear()

tsne = manifold.TSNE(n_components=2, init='random',
                    random_state=0, perplexity=50)
Y = tsne.fit_transform(X_ipca)

area = np.full(Y.shape, 40)
plt.scatter(Y[bag_of_labels == 1,0], Y[bag_of_labels == 1,1], s=area, c=colors[0])
plt.scatter(Y[bag_of_labels == 2,0], Y[bag_of_labels == 2,1], s=area, c=colors[1])
plt.scatter(Y[bag_of_labels == 3,0], Y[bag_of_labels == 3,1], s=area, c=colors[2])
plt.scatter(Y[bag_of_labels == 4,0], Y[bag_of_labels == 4,1], s=area, c=colors[3])
plt.scatter(Y[bag_of_labels == 5,0], Y[bag_of_labels == 5,1], s=area, c=colors[4])
plt.scatter(Y[bag_of_labels == 6,0], Y[bag_of_labels == 6,1], s=area, c=colors[5])

navy_patch = mpatches.Patch(color='navy', label='BOX')
turquoise_patch = mpatches.Patch(color='turquoise', label='CLAP')
```

```
dark_orange_patch = mpatches.Patch(color='darkorange', label='WAVE')
red_patch = mpatches.Patch(color='red', label='RUN')
gold_patch = mpatches.Patch(color='wheat', label='WALK')
#yellow_patch = mpatches.Patch(color='yellow', label='JOGG')
plt.legend(handles=[navy_patch, turquoise_patch, dark_orange_patch, red_patch, gold_patch])

plt.show()
```

Listing B.1: Test TSNE

## C Výpis sublime

```
../.. / fei .sublime-project
```

Listing C.1: Ukážka sublime-project